

Sistemas inteligentes

1) Decisiones tomadas

- **Tratamiento y Limpieza de Datos:** Durante el Análisis Exploratorio (EDA), se constató que el dataset asignado no contiene valores faltantes ni variables categóricas en texto. Por lo tanto, no se requirió aplicar técnicas de imputación ni codificación.
- **Transformación del Problema:** Si bien la variable original representaba el precio continuo de las viviendas, se tomó la decisión estratégica de convertirlo en un problema de **clasificación binaria**. Para ello, se calculó el precio promedio de entrenamiento y se utilizó como umbral para segmentar las propiedades en "Barata (0)" y "Cara (1)".
- **Preprocesamiento Seguro:** Se implementó una normalización con StandardScaler, la cual fue ajustada exclusivamente sobre los datos de entrenamiento para prevenir la fuga de datos hacia el conjunto de prueba. Sin embargo, para alimentar los algoritmos finales basados en árboles, se utilizaron directamente las variables sin escalar, ya que su estructura matemática no lo requiere.

2) Resultados Obtenidos

Se entrenaron y evaluaron dos algoritmos distintos, midiendo su eficacia sobre un conjunto de prueba de 4128 instancias:

- Decision Tree Classifier (Profundidad Máxima = 5):
 - Exactitud en Entrenamiento: **83.0%**
 - Exactitud en Prueba: **82.3%**
- Random Forest Classifier (Estimadores = 100, Profundidad Máxima = 10):
 - Exactitud en Entrenamiento: **91.8%**
 - Exactitud en Prueba: **87.3%**

Ambos algoritmos identificaron con mayor facilidad y volumen las propiedades baratas, obteniendo en el Random Forest un F1-score de 0.90 para la clase "Barata" frente a un 0.83 para la clase "Cara".

3) Conclusiones

- El modelo de **Random Forest** demostró ser notablemente superior al Árbol de Decisión simple. Logró predecir correctamente la categoría de la vivienda el 87% de las veces en datos no vistos. Aunque exhibe una leve diferencia frente a su 91.8% en entrenamiento, es el candidato ideal para ser desplegado.
- A nivel del dominio del negocio, el análisis de datos reveló que el nivel de ingresos del barrio (MedInc) es la variable con mayor correlación frente a la variable objetivo. Esta relación es lógicamente robusta: las zonas donde habitan familias de mayores ingresos impulsan un marcado encarecimiento en el precio de mercado de sus viviendas de manera proporcional.